



Ingeniería de Datos

Data Warehouse


Rosario Guzmán, Milo Flores
Fernando Arimana, Pedro Wong

Junio 2006


Agenda

- Introducción
- Concepto de Data Warehouse, Data Mart
- Arquitectura
- Tipos de implementación
- Extracción, transformación y carga de datos - ETL
- Metadatos
- Cubos de datos
- Explotación de datos
- Beneficios


Infraestructura e-Business



Diversidad de Fuentes de Datos




Productividad de los Usuarios de Negocios




Source: Gartner Group

Productividad de los Usuarios de Negocios




Source: Gartner Group

Brecha del Conocimiento Creciente




Source: Gartner Group

Data Warehousing



Transformación, Filtrado, Limpieza



Data Warehouse



Gestión de Información

Decision Support

**Data
Mart**

Análisis Multi-
Dimensional

Data Mining

Business Intelligence

Data Warehouse

Star Schema

Operational Data Store (ODS)


Executive Information System (EIS)

Sistemas de Información Gerencia (SIG)

On-Line
Analytical
Processing
(OLAP)
RDBMS

Metadatos

Data Warehousing



Data Warehouse

data warehouse n. Area de almacenamiento para Información como Soporte para Toma de Decisiones. Almacena Data recolectada de Sistemas Operacionales Diversos y Externos, Integra la Data en un Modelo de Negocios, Permite el Análisis de la Data y Entrega Información a las personas de Toma de Decisiones a lo largo de la Organización.

Data Mart

data mart *n.* Areas de Almacenamientos de Grupos de Trabajo o Departamentales que son Pequeños en tamaño y Especializados en Funciones. El Data Mart contiene Data Informacional que es ajustada a las Necesidades de Departamentos de Trabajo Específicos. También ofrece Mejoras de Performance.

En otras palabras

Presenta una vista de Unidad de Negocio de la Información
Usualmente Creada para Mejorar Performance de Acceso/Análisis


Según una definición formal de Bill Inmon:

Organizada por Temas: Información del mismo evento o tema relacionada.
Variante en el Tiempo: Los cambios en la data son auditables,
No Volatil: Información permanente,
Integrada: Amplia y Consistente

Diferencias entre Sistemas Operacionales y Sistemas Analíticos

Sistemas Operacionales

- Ejecuta el negocio
- Empleado por
 - Oficinistas/administradores
- Data Actualizada al segundo
- Altos Volúmenes de Transacciones simples
- Rápido tiempo de respuesta




Sistemas Analíticos

- Administra el negocio
- Empleado por
 - Decision makers
 - Empleados con experiencia
- Detallado y sumarizado
- Integrado
- Histórico


Arquitectura



Arquitectura Referencial



Ambiente de Trabajo MS




Tipos de Implementación




Implementación:


Data Warehouse -> Data Mart



Implementación: Data Mart -> Data Warehouse



Integrando Data Marts




Extracción, Transformación y Carga de datos (ETL)


“80% del tiempo y recursos necesarios para crear y mantener un Data Warehouse son necesarios en la Extracción, Limpieza y Carga de la Data”.

Source: Bill Immon

Extracción, Transformación y Carga de datos




Herramienta ETL - Warehouse Manager



Warehouse Manager


- Registra y accede a las fuentes de datos
DB2, Oracle, Microsoft, Sybase,
Informix, archivos planos y otros
- Define extracciones y transformaciones
Mas de 100 transformaciones
incorporadas
- Define carga y actualización del warehouse
Full refresh, histórico, y movimiento de datos
- Modela, automatiza, y monitorea procesos
Programa, triggers, dependencias, reintentos y
notificaciones
- Maneja e intercambia metadatos
Basados en estandars OMG CWMI




Metadatos



Metadatos - Diversidad de Componentes



Metadata - Arquitectura




Metadatos - De dónde vienen los Datos?




Calidad de Datos



Calidad de Datos - Metodología




Calidad de Datos - Metodología





Cubos de Datos



Cubos de Datos

- Los metadatos en data warehouse se representan a través de “cubo de datos” multidimensionales.
- Componentes:
 - Dimensiones
 - Ej: parte p, proveedor s, cliente c
 - Hechos o Fact (Medidas de interés)
 - Ej: ventas totales
 - Cubo de Datos 3-D
 - Ej: para cada celda (p,s,c), ventas totales de p que fueron compradas a s y fueron vendidas a c

Definiciones

- **Tablas Fact**
 - Tambien conocidas como *Tablas de Hecho*, estas son las tablas centrales en un esquema estrella de un modelo DW. Los tablas fact representan el conocimiento del negocio y sus datos generalmente son numéricos y/o añadidos para ser analizados.
- **Tablas Dimensión**
 - También conocidas como *Tablas de la Referencia*, contienen los datos relativamente estáticos en el DW. Una dimensión es una estructura, integrada a menudo por unas o más jerarquías, que categoriza datos.
 - **Jerarquías**
 - Las jerarquías son las estructuras lógicas que utilizan niveles pedidos como los medios de ordenamiento de datos.

Índices


■ Índices Bitmap

- Ideales para búsquedas en gran cantidad datos y consultas ad hoc, reduce substancialmente del uso del espacio comparado con a otras técnicas de la indexación y su mantenimiento es muy eficiente durante consultas DML en paralelo y cargas de datos.


■ Índices del B-tree

- Un índice del b-tree ordena los datos como un árbol inverso. El nivel mas bajo del índice mantiene los valores reales de los datos y los punteros a las filas correspondientes. Este es utilizado mayormente para acceso de consultas típicas.

Esquema Básico




¿Qué es una Dimensión?



- Una dimensión describe las relaciones entre datos.
- Definido por la referenciación de tablas en la Base de Datos.
- Puede ser usada en una BD normalizada o desnormalizada.

Nombre del mes

Cubo de Datos



Dimensiones:

Tiempo, Producto, Geografía

Atributos:

Productos (upc, precio, ...)

Geografía ...

Jerarquias:

Producto → Clase → ...

Dia → Semana → Semestre

Ciudad → Region → País

Ejemplo de Dimensión

```
CREATE DIMENSION time_dim
    LEVEL time_key IS time.time_key
    LEVEL month IS time.month
    LEVEL quarter IS time.quarter
    LEVEL year IS time.year
    LEVEL week IS time.week
    LEVEL fiscal_qtr IS time.fiscal_qtr

    HIERARCHY calendar_rollup (
        time_key CHILD OF
        month CHILD OF
        quarter CHILD OF year )
    HIERARCHY fiscal_rollup (
        time_key CHILD OF
        week )

    ATTRIBUTE time_key DETERMINES
        (day_number_in_month, day_number_in_year)
    ATTRIBUTE week DETERMINES week_number_of_year
    ATTRIBUTE month DETERMINES full_month_name;
```



nombre

Define el nombre de cada nivel en la dimension y la columnas de la tabla


Describe la jerarquia usando niveles de nombres

atributos que son unicos por nivel

Desnormalización vs Normalización



VS



Esquema Estrella

Product Dimension

| product key |
|-----------------|
| product name |
| product size |
| product form |
| product package |
| product dept |
| product cat |
| product subcat |
| ... |

Organization Dimension

| organization key |
|------------------|
| division name |
| area name |
| region name |
| market name |
| ... |

Sales Fact

| product key |
|-----------------------|
| organization key |
| store key |
| time key |
| units sold qty |
| lcl currency sale amt |
| US\$ sale amount |
| US\$ cost amount |
| product gross margin |
| intercompany profit |
| royalty amount |
| ... |

Store Dimension

| store key |
|-----------------|
| store name |
| store address |
| store manager |
| floor plan type |
| store size |
| ... |

Time Dimension

| time key |
|-----------|
| time date |
| week |
| month |
| quarter |
| year |
| ... |

Aplicación de un Modelo de Datos

Dimensiones, Niveles, Jerarquías y Atributos



Variables


Dimensiones (producto, tiempo, geografía, canal)

Unidades (patrón{todos, algunos, uno}, segmentos{mercado, zonas})




Tipos de Cubos


ROLAP



MOLAP



HOLAP



Explotación de Datos



Explotación de Datos



✓ Query Ad hoc – Consultas Ad hoc

- Proceso Iterativo de Preguntas y Respuestas
- Herramienta que asiste a experto a encontrar información valiosa

✓ OLAP - Análisis Multidimensional

- Preguntas Multidimensionales/Respuestas Multidimensionales
- Consultas Complejas - Herramienta que ayuda al usuario experto


✓ Data Mining - Minería de Datos

- Herramienta que automáticamente busca tendencias y patrones
- Herramienta que aprende y desarrolla experiencia
- Puede ser la base para análisis detallado

Data Mining

- Es el proceso que permite al usuario conocer la esencia y las relaciones entre sus datos.
- Data mining descubre patrones y tendencias en el contenido de la información almacenada en el warehouse a través de las diferentes técnicas que utiliza.

Proceso de Data Mining




Tipos de Minería

- ✓ **Minería de Descubrimiento** - Encontrar patrones en Datos que pueden ser usados para guiar decisiones.
 - Minimiza dirección de la minería
 - Analiza todo el almacén de datos
 - Minería de "fácil". Algunas veces la más valiosa.

- ✓ **Minería Predictiva** - Usar resultados conocidos para crear modelos que puedan predecir valores futuros.
 - Extensiva dirección del minador
 - Aprende de las muestras para aplicar la población
 - Minería "Dura". Un experto usuario es requerido.

Técnicas Data Mining



Beneficios



ROI y Beneficios de la Solución

- ✓ Las organizaciones que han implementado y utilizado aplicaciones analíticas han logrado retornos en un rango desde 17% a 2000% con una media de ROI de 112%.
- ✓ Cerca de la mitad (49%) de estos han tenido un periodo de recuperación de menos de un año.
- ✓ Los resultados en el área financiera utilizando sistemas analíticos tienen una media de ROI de 139%.
- ✓ El costo de generación de reportes se reduciría en aprox. 60%.
- ✓ El tiempo total de generación de reportes se reduce de 10 a 1

Source: IDC

Beneficios

✓ **Desde perspectiva IT**

- Arquitectura flexible de data warehousing que me permita cambiar cuando lo necesite
- Presupuestos limitados
- Procesos que automáticamente actualicen los datos del data warehousing
- Desgaste del area de IT por requerimientos de usuarios

✓ **Desde perspectiva de usuarios finales**

- Tener una vista global de los datos de la organización, no importando de donde provenga la información
- Tener una herramienta fácil de usar
- Tener la capacidad de generar reportes de manera independiente
- Acceso desde internet o intranet